

Recolección y análisis de la evolución de precios de pañales

Una arquitectura ETL con extracción asistida por LLM y seguimiento temporal

Victorio Scafati — 151038

Resumen. Este trabajo aborda un proceso de extracción, transformación y carga (ETL) de precios de pañales publicados en e-commerce de la Provincia y la Ciudad de Buenos Aires, con foco en construir una serie temporal que permita analizar y proyectar el gasto a lo largo de la crianza. A diferencia de un relevamiento puntual, la recolección periódica habilita el estudio de la evolución de precios — especialmente relevante en un contexto de alta inflación— y la estimación de costos futuros. El pipeline incorpora extracción asistida por modelos de lenguaje (LLM) para normalizar y estructurar las descripciones de los productos, una etapa de clasificación de talles apoyada en una tabla de referencia, y el cruce con tablas de percentiles de peso-para-la-edad de la OMS para estimar, por género y percentil de crecimiento, el gasto total en pañales durante los primeros meses de vida.

Palabras clave: *ETL · web scraping · modelos de lenguaje · series temporales · análisis de precios · OMS*

1. Introducción

Los pañales son un insumo imprescindible durante los primeros años de crianza y representan una porción significativa del gasto mensual de manutención de un bebé [1]. Resulta de interés relevar sus precios en los e-commerce de la región para estimar el gasto total durante la etapa en que se utilizan, cruzando esa información con percentiles de crecimiento en kilogramos para niños y niñas [2].

Un relevamiento realizado una única vez tiene una utilidad limitada: no permite proyectar costos ni observar tendencias. Esta limitación se vuelve crítica en el contexto argentino reciente, donde la inflación anual fue de 211 % en 2023, 118 % en 2024 y aproximadamente 32 % en 2025 [3]. Bajo esas condiciones, una lista de precios queda desactualizada en pocas semanas. Por ese motivo, el trabajo se reformula en torno a una recolección periódica que construya una serie temporal de precios, base sobre la cual sí es posible analizar la evolución y estimar costos futuros.

Adicionalmente, la composición del mercado cambió. Si bien tres marcas (Huggies, Pampers y Babysec) concentran buena parte de las ventas, en los catálogos actuales conviven numerosas marcas económicas y alternativas (Estrella, Chelino, Nene, Kimbies, opciones ecológicas y marcas propias de supermercado) [4]. El diseño debe contemplar esta diversidad y no asumir un conjunto fijo de tres competidores.

Objetivos

- Relevar de forma periódica precio y descripción de pañales en e-commerce de la Provincia y Ciudad de Buenos Aires, construyendo una serie temporal de observaciones.
- Estructurar y enriquecer cada producto mediante extracción asistida por LLM, identificando: marca, talle, unidades por paquete, precio unitario y rango de peso soportado (KG).
- Cruzar los productos con percentiles de crecimiento (OMS) para niños y niñas, determinando los meses de vida en que cada producto resulta utilizable.
- Estimar el gasto total en pañales por género y percentil, y proyectar costos futuros a partir de la serie temporal.
- Construir un tablero de control para el análisis gráfico de los datos recabados.

2. Materiales y Métodos

El procesamiento se ejecuta de forma programada (por ejemplo, diaria o semanal) mediante un orquestador (Airflow, Dagster o Prefect). En cada corrida, los scrapers extraen los items de cada sitio; luego una etapa de extracción asistida por LLM estructura y normaliza las descripciones; se clasifican los talles y se cruzan con las tablas de percentiles; finalmente las observaciones se validan y se cargan en un almacén orientado a series temporales que alimenta el tablero. La Figura 1 resume el flujo.




Figura 1. Workflow ETL con ingestión periódica y extracción asistida por LLM.

2.1 Extracción

La extracción dentro de cada sitio se realiza con scrapers específicos que contemplan su lógica particular: búsqueda de items, manejo de paginado y extracción de resultados. Un scraper transforma fuentes semi-estructuradas (HTML, XML) en datos estructurados (CSV, JSON). Para sitios cuyo contenido se renderiza con JavaScript o que incorporan defensas anti-scraping, se utiliza un navegador headless (Playwright) en lugar de descargas HTTP simples. Se respeta robots.txt y se aplica rate limiting para no sobrecargar los servidores. En marketplaces que ofrecen API oficial (por ejemplo, Mercado Libre) se prioriza su uso sobre el scraping.

Cada observación se registra con su marca temporal (scraped_at), lo que constituye la base de la serie de tiempo. Antes de cada ciclo se verifica la disponibilidad de las fuentes, dado que el conjunto puede variar con los años. Entre los sitios candidatos se incluyen panaleras online y las secciones de pañales de los principales supermercados (Coto, Jumbo, Carrefour) y marketplaces (Mercado Libre).

2.2 Transformación

El objetivo de esta etapa es transformar los atributos crudos (precio y descripción) en una estructura rica. Los atributos resultantes son:

- **price:** precio por paquete.
- **description:** descripción del item.
- **brand:** marca.
- **size:** talle del pañal.
- **units:** unidades por paquete.
- **unit_price:** precio unitario (price / units).
- **target_kg:** rango de peso soportado (mínimo y máximo).

- **website / url:** vendedor y enlace al producto.
- **scraped_at:** fecha de la observación.

2.2.1 Extracción de atributos con LLM

En la propuesta original, la normalización y la segmentación se planteaban como etapas basadas en reglas (corrección ortográfica, diccionarios de sinónimos, expresiones regulares), un enfoque frágil ante la variedad de formatos. En su lugar, se utiliza un modelo de lenguaje al que se le entrega la descripción cruda y se le solicita una salida JSON conforme a un esquema predefinido. Esto resuelve en un solo paso la normalización y la extracción de marca, talla, unidades y rango de peso, tolerando typos, abreviaturas y variantes de redacción. Por ejemplo, de la descripción «Huggies Supreme Care XXG (+14 Kg) - x100» se obtiene directamente:

```
{
  "brand": "huggies",
  "size": "xxg",
  "units": 100,
  "price": 1527.99,
  "unit_price": 15.27,
  "target_kg": { "min": 14, "max": null }
}
```

Para acotar costo y latencia a escala, se contemplan: el cacheo de descripciones ya procesadas (las listas cambian poco entre corridas), el procesamiento por lotes, el uso de un modelo de menor costo para los casos frecuentes y la validación de la salida contra el esquema (con Pydantic), descartando o reintentando los casos que no validan.

2.2.2 Clasificación de talles

Cuando la descripción ya indica el rango de peso, se toma directamente de allí. Cuando no, se recurre a una tabla de referencia que mapea cada talla de cada marca a los KG soportados. Dado que el mercado incorporó nuevas marcas y talles (por ejemplo, XXXG), la tabla se mantiene extensible. La Tabla 1 muestra la referencia para las tres marcas principales.

Talle	Huggies	Pampers	Babysec
PR — Prematuro	Hasta 2,2 kg	—	—
RN — Recién nacido	Hasta 4 kg	Hasta 4,5 kg	Hasta 4,5 kg
RN — Recién nacido (+)	—	3 a 6 kg	—
P — Pequeño	3,5 a 6 kg	5 a 7,5 kg	Hasta 6 kg
M — Mediano	5,5 a 9,5 kg	6 a 9,5 kg	5 a 9,5 kg
G — Grande	9 a 12,5 kg	9 a 12 kg	8,5 a 12 kg
XG — Extra Grande	12 a 15 kg	12 a 15 kg	11 a 14 kg
XXG — Extra Extra Grande	Más de 14 kg	Más de 14 kg	Más de 13 kg

Tabla 1. Referencia de talles para las principales marcas (KG soportados). Estructura extensible a nuevas marcas y talles.

2.2.3 Incorporación de percentiles

Se cruzan los rangos de peso de cada producto con las tablas de peso-para-la-edad de la OMS [2], que expresan, mes a mes, el peso esperado para cada percentil (de SD3neg a SD3) en niñas y niños (tablas diferentes por género). La Tabla 2 muestra un fragmento de la tabla para niñas.

Mes	SD3neg	SD2neg	SD1neg	SD0	SD1	SD2	SD3
0	2,0	2,4	2,8	3,2	3,7	4,2	4,8
1	2,1	2,5	2,9	3,3	3,9	4,4	5,1
2	2,3	2,7	3,1	3,6	4,1	4,7	5,4
3	2,5	2,9	3,3	3,8	4,4	5,0	5,7
...	...	...	...	...	...	...	...
28	8,4	9,4	10,5	11,9	13,5	15,4	17,7

Tabla 2. Fragmento de la tabla de percentiles peso-para-la-edad (niñas), OMS. Valores en KG.

Del cruce se obtiene, para cada producto, la lista de meses de vida en que resulta utilizable según cada percentil. El registro enriquecido resultante adopta la siguiente forma:

```
{
  "brand": "huggies",
  "size": "xxg",
  "target_kg": { "min": 14, "max": null },
  "units": 100,
  "price": 1527.99,
  "unit_price": 15.27,
  "description": "Huggies Supreme Care XXG (+14 Kg) - x100",
  "website": "panalesonline.com.ar",
  "url": "https://www.panalesonline.com.ar/...",
  "scraped_at": "2026-06-19T10:00:00Z",
  "percentil_girls": {
    "sd0": null, "sd1": null, "sd2": [28, ...], "sd3": [28, ...]
  },
  "percentil_boys": {
    "sd0": null, "sd1": null, "sd2": [28, ...], "sd3": [28, ...]
  }
}
```

2.2.4 Consumo de pañales

En lugar de una constante única, el consumo diario promedio se modela como una función del tramo de edad: los recién nacidos usan del orden de 8 a 12 unidades diarias, cantidad que disminuye con los meses. El tablero permite ajustar este parámetro y su desvío, dada la variabilidad entre bebés.

2.3 Carga y almacenamiento

Las observaciones se almacenan en un esquema orientado al análisis: una tabla de hechos append-only de observaciones de precio (producto, sitio, precio, scraped_at) y tablas de dimensiones (productos, tabla de talles, percentiles). Por el carácter temporal y multidimensional de los datos, se emplea un almacén columnar/analítico: DuckDB para un entorno local y liviano, o Postgres con TimescaleDB, ClickHouse o BigQuery para mayor escala. Para el volumen de este trabajo, el procesamiento en un único nodo con Polars o DuckDB resulta suficiente; un motor distribuido como Spark se justificaría sólo ante un crecimiento sustancial del volumen.

2.4 Calidad de datos y observabilidad

El pipeline incorpora validación de esquema (Pydantic o pandera), detección de outliers de precio (por ejemplo, mediante z-score sobre el precio unitario) y monitoreo de la salud de los scrapers, que se rompen cuando los sitios modifican su HTML. Estas verificaciones permiten detectar tempranamente datos anómalos o fuentes caídas, evitando que contaminen la serie temporal.

3. Resultados esperados

A partir de los datos recolectados se construye un tablero de control (Metabase, Superset o similar) que indique:

- Precio y precio unitario promedio por marca, agrupado por talle.
- Evolución temporal de precios por marca y talle, y comparación de la inflación de la categoría contra el IPC del INDEC.
- Combinaciones de marca (brand) y talle (size) que en promedio minimicen el costo total durante los primeros n meses de vida, agrupadas por percentil y género.
- Combinaciones de items específicos que minimicen ese costo total.
- Acumulado total de gasto en pañales durante los primeros n meses de vida, agrupado por marca, percentil y género.
- Proyección del costo futuro a partir de la serie temporal, expresada en términos reales (deflactada por IPC) o en dólares para su comparabilidad en el tiempo.

En el tablero se podrán modificar los siguientes parámetros:

- **avg_daily_diaper_usage**: promedio de uso diario de pañales (por tramo de edad).
- **dev_daily_diaper_usage**: desvío del promedio de uso diario de pañales.

4. Consideraciones finales

La recolección respeta los términos de uso de los sitios, robots.txt y límites de tasa razonables. El parámetro de consumo diario, al no contar con un dato único y dada su alta variabilidad, se modela de forma parametrizable dentro del tablero. La extensión final del trabajo no supera las 14 páginas, incluyendo figuras y referencias.

Referencias

- [1] Infobae (2020). Baby boom en cuarentena: cuánto cuesta el ajuar del recién nacido, la canasta de cuidado y la alimentación mensual. [infobae.com](https://www.infobae.com)
- [2] Organización Mundial de la Salud. Child growth standards: weight-for-age. [who.int](https://www.who.int)
- [3] INDEC. Índice de Precios al Consumidor (IPC), serie 2023–2026.
- [4] Relevamiento propio en e-commerce de pañales (Provincia y Ciudad de Buenos Aires), 2026.